

# 数字图像处理

# Digital Image Processing

刘利刚

[lgliu@ustc.edu.cn](mailto:lgliu@ustc.edu.cn)

<http://staff.ustc.edu.cn/~lgliu>

Graphics&Geometric Computing Lab  
@USTC



# **Image as A Function**

Fitting: Interpolation and Approximation


# Gray Images

- A function (height field) over 2D domain




# Color Images



- Vector function over 2D domian




# Image: Discrete Sampling




# Gradient (梯度)




# Downsampling



# Upsampling (Super-resolution)



Without Super Resolution



Super Resolution


# 函数插值（拟合）

详细可参考：

<https://www.bilibili.com/video/BV1NA411E7Yr> (P2-P4三节课程视频)  
[http://staff.ustc.edu.cn/~lgliu/Courses/GAMES102\\_2020/default.html](http://staff.ustc.edu.cn/~lgliu/Courses/GAMES102_2020/default.html)


# 函数 (Function)

- 非空**实数集**之间的映射称为（一元）函数 $y = f(x)$ , 或变换
- 函数的图像（函数的可视化）：所有有序对 $(x, f(x))$ 组成的集合




# 一元函数


- 有哪些函数?
  - 幂函数
  - 三角函数
  - 对数函数
  - 指数函数
  - 三角函数
  - 反三角函数
  - ...




幂函数



指数函数



对数函数



(反)三角函数

# 函数的集合（函数空间）

- 用若干简单函数（“基函数”）线性组合张成一个函数空间
  - $L = \text{span}\{f_1, f_2, \dots, f_n\} = \{\sum_{i=1}^n a_i f_i(x) \mid a_i \in R\}$
  - 每个函数就表达（对应）为  $n$  个实数，即系数向量  $(a_1, a_2, \dots, a_n)$

幂基  $\{x^k, k = 0, 1, \dots, n\}$



$$f(x) = \sum_{k=0}^n w_k x^k$$

多项式函数空间

三角函数基



$$f(x) = a_0 + \sum_{k=1}^n (a_k \cos kx + b_k \sin kx)$$

三角函数空间

空间的完备性：这个函数空间是否可以表示（逼近）任意函数？

# 赋范空间

- 内积诱导范数、距离

- $\langle f, g \rangle = \int_a^b f(x)g(x)dx$

- 度量空间：可度量函数之间的距离

- $Lp$ 范数

- 赋范空间+完备性=巴拿赫空间

- 内积空间（无限维）+完备性=希尔伯特空间

# 万能逼近定理： Weierstrass逼近定理

- 定理1：闭区间上的连续函数可用多项式级数一致逼近
- 定理2：闭区间上周期为 $2\pi$ 的连续函数可用三角函数级数一致逼近


对  $[a, b]$  上的任意连续函数  $g$ , 及任意给定的  $\varepsilon > 0$ , 必存在  $n$  次代数多项式  $f(x) = \sum_{k=0}^n w_k x^k$ , 使得

$$\min_{x \in [a, b]} |f(x) - g(x)| < \varepsilon.$$


# 傅里叶级数

$$f(t) = A_0 + \sum_{n=1}^{\infty} [a_n \cos(n\omega t) + b_n \sin(n\omega t)]$$

$$f(t) = A_0 + \sum_{n=1}^{\infty} A_n \sin(n\omega t + \psi_n)$$



# 更复杂的函数：函数复合



$$f = f_k \circ f_{k-1} \circ \dots \circ f_0$$


$$\frac{1}{1 + \left( \frac{2x}{1+x^2} \right)^2}, \quad f(x) = \frac{e^x}{x^2+1}$$

# 问题：如何求满足要求的函数？

- 大部分的实际应用问题
  - 可建模为：找一个映射/变换/函数
  - 输入不一样、变量不一样、维数不一样
- 如何找函数的三步曲：
  - 到哪找?
    - 确定某个函数集合/空间
  - 找哪个?
    - 度量哪个函数是好的/“最好”的
  - 怎么找?
    - 求解或优化：不同的优化方法与技巧，既要快、又要好...
- 【注】这里先暂时限定为单变量的函数形式

# 曲线/曲面拟合问题

- 输入：一些型值（采样）点集
- 输出：一条拟合这些点集的曲线/曲面




采样点云

光滑曲面

# 数据拟合

# 拟合(Fitting)问题

- 输入：一些观察的数据点
- 输出：反映这些数据规律的函数  $y = f(x)$




$$x \in R^1, y \in R^1$$

# 1. 到哪找？

- 选择一个函数空间
  - 线性函数空间  $A = \text{span}\{B_0(x), \dots, B_n(x)\}$ 
    - 多项式函数  $\text{span}\{1, x, x^2, \dots, x^n\}$
    - RBF函数
    - 三角函数
- 函数表达为
  - $f(x) = \sum_{k=0}^n a_k B_k(x)$
  - 求  $n + 1$  个系数  $(a_0, \dots, a_n)$  待定系数

## 2. 找哪个？

- 目标1：函数经过每个数据点（**插值**）
  - $y_i = f(x_i), i = 0, 1, \dots, n$



### 3. 怎么找？

- 目标1：每个数据点都要插值（零误差）
  - $y_i = f(x_i), i = 0, 1, \dots, n$
- 联立，求解线性方程组：
  - $\sum_{k=0}^n a_k B_k(x_i) = y_i, i = 0, 1, \dots, n$ 
    - 求解 $(n + 1) \times (n + 1)$ 线性方程组
    - $n$ 次Langrange插值多项式
  - 病态问题：系数矩阵条件数高时，求解不稳定

# Lagrange插值函数

- 插值 $n+1$ 个点、次数不超过 $n$ 的多项式是存在而且是唯一的
  - ( $n+1$ 个变量,  $n+1$ 个方程)


$$p_k(x) = \prod_{i \in B_k} \frac{x - x_i}{x_k - x_i}$$

插值函数的**自由度** = 未知量个数 – 已知量个数

## 2-2. 找哪个？

- 目标2：函数尽量靠近数据点（逼近）

$$-\min \sum_{i=0}^n (y_i - f(x_i))^2$$





## 3-2. 怎么找？

- 目标2：函数尽量靠近数据点（逼近）
  - $\min \sum_{i=0}^n (y_i - f(x_i))^2$
- 对各系数求导，得法方程（线性方程组）
  - $AX = b$
- 问题：
  - 点多，系数少？
  - 点少，系数多？


最小二乘法

# Recap: 拟合--插值或逼近




# Overfitting (过拟合)

- 误差为0，但是拟合的函数并无使用价值！




# 欠拟合或过拟合

- 如何选择合适的基函数？




$$w_0 + w_1 x$$

High bias  
(underfitting)



$$w_0 + w_1 x + w_2 x^2$$

“Just right”



$$w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

High variance  
(overfitting)

- 需要根据不同的应用与需求，不断尝试  
(不断“调参”)

# 避免过拟合的常用方法

- 数据去噪
  - 剔除训练样本中噪声
- 数据增广
  - 增加样本数，或者增加样本的代表性和多样性
- 模型简化
  - 预测模型过于复杂，拟合了训练样本中的噪声
  - 选用更简单的模型，或者对模型进行裁剪
- 正则约束
  - 适当的正则项，比如方差正则项、稀疏正则项

$$y = \sum_{i=0}^n w_i B_i(x)$$

# 岭回归正则项

- 选择一个函数空间

- 基函数的线性表达  $W = (w_0, w_1, \dots, w_n)$

$$y = f(x) = \sum_{i=0}^n w_i B_i(x)$$

- 最小二乘拟合

$$\min_W \|Y - XW\|^2$$

- Ridge regression (岭回归)

$$\min_W \|Y - XW\|^2 + \mu \|W\|_2^2$$


# 稀疏学习：稀疏正则化

- 冗余基函数（过完备）
- 通过优化来选择合适的基函数
  - 系数向量的 $L_0$ 模（非0元素个数）尽量小
  - 挑选（“学习”）出合适的基函数

$$\min_{\alpha} \|Y - XW\|^2 + \mu \|W\|_0$$

$$\min_{\alpha} \|Y - XW\|^2, \quad \text{s.t. } \|W\|_0 \leq \beta$$

思考：非函数型的曲线拟合？



# 求拟合函数：应用驱动

- 大部分的实际应用问题
  - 可建模为：找一个映射/变换/函数
  - 输入不一样、变量不一样、维数不一样
- 三步曲方法论：
  - 到哪找？
    - 确定某个函数集合/空间
  - 找哪个？
    - 度量哪个函数是好的/“最好”的
  - 怎么找？
    - 求解或优化：不同的优化方法与技巧，既要快、又要好...

# 数据拟合的方法论

- 到哪找?

- 确定函数的表达形式（函数集、空间） $L = \text{span}\{b_0(x), \dots, b_n(x)\}$
  - 待定基函数的组合系数（求解变量） $f_\lambda(x) = \sum_{k=0}^n \lambda_i b_i(x)$

- 找哪个?

- 优化模型（最小化问题）
    - 能量项 = 误差项 + 正则项
  - 统计模型、规划模型...

$f$ 由待定系数  $\lambda = \begin{pmatrix} \lambda_1 \\ \dots \\ \lambda_n \end{pmatrix}$  确定

- 怎么找?

- 求解误差函数的驻点（导数为0之处）
  - 转化为系数的方程组
    - 如果是欠定的（有无穷多解），则修正模型
      - 改进/增加各种正则项：Lasso、岭回归、稀疏正则项...
      - 返回修改模型

# 1. 多项式插值

# 多项式插值定理

定理：若  $x_i$  两两不同，则对任意给定的  $y_i$ ，存在唯一的次数至多是  $n$  次的多项式  $p_n$ ，使得  $p_n(x_i) = y_i \quad i = 0, \dots, n$ 。

证明：在幂基  $\{1, x, \dots, x^n\}$  下待定多项式  $p$  的形式为：

$$p(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$$

由插值条件  $p(x_i) = y_i, i = 0, \dots, n$ ，得到如下方程组：

$$\begin{pmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ 1 & x_2 & x_2^2 & \dots & x_2^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

如果基函数选取不一样，方程组的系数矩阵不同

系数矩阵为 Vandermonde 矩阵，其行列式非零，因此方程组有唯一解。

# 技巧1：构造插值问题的通用解

- 构造插值问题的通用解
  - 给定  $n + 1$  个点  $\{(x_0, y_0), \dots, (x_n, y_n)\}$ , 寻找一组次数为  $n$  的多项式基函数  $l_i$  使得

$$l_i(x_j) = \begin{cases} 1, & \text{若 } i = j \\ 0, & \text{若 } i \neq j \end{cases}$$

- 插值问题的解为：

$$P(x) = y_0 l_0(x) + y_1 l_1(x) + \cdots + y_n l_n(x) = \sum_{i=0}^n y_i l_i(x)$$

# 一般形式

- 怎么计算多项式  $l_i(x)$ ?
  - $n$  阶多项式, 且有以下  $n$  个根

$$x_0, x_1, x_2, \dots, x_{i-1}, x_{i+1}, \dots, x_n$$

– 故可表示为

$$\begin{aligned} l_i(x) &= C_i(x - x_0)(x - x_1) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n) \\ &= C_i \prod_{j \neq i} (x - x_j) \end{aligned}$$

– 由  $l_i(x_i) = 1$  可得

$$1 = C_i \prod_{j \neq i} (x_i - x_j) \Rightarrow C_i = \frac{1}{\prod_{j \neq i} (x_i - x_j)}$$

# 技巧1：构造插值问题的通用解

- 最终多项式基函数为

$$l_i(x) = \frac{\prod_{j \neq i} (x - x_j)}{\prod_{j \neq i} (x_i - x_j)}$$

- 多项式 $l_i(x)$ 被称为**拉格朗日多项式**

# 技巧2：更方便的求解表达

- Newton插值：具有相同“导数”（差商）的多项式构造（ $n$ 阶Taylor展开）

定义：

一阶差商：

$$f[x_0, x_1] = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$$

$k$  阶差商：

设  $\{x_0, x_1, \dots, x_k\}$  互不相同， $f(x)$  关于  $\{x_0, x_1, \dots, x_k\}$  的  $k$  阶差商为：

$$f[x_0, x_1, \dots, x_k] = \frac{f[x_1, \dots, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_0}$$

所以 Newton 插值多项式表示为：

$$N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x_0, x_1, \dots, x_n](x - x_0) \cdots (x - x_{n-1})$$

# 多项式插值存在的问题

- 系统矩阵稠密
- 依赖于基函数选取，矩阵可能病态，导致  
难于求解（求逆）

# 病态矩阵示例

- 考虑二元方程组
  - 解为(1,1)

$$\begin{aligned}x_1 + 0.5x_2 &= 1.5 \\0.667x_1 + 0.333x_2 &= 1\end{aligned}$$

- 对第二个方程右边项扰动0.001
  - 解为(0, 3)

$$\begin{aligned}x_1 + 0.5x_2 &= 1.5 \\0.667x_1 + 0.333x_2 &= 0.999\end{aligned}$$

- 对矩阵系数进行扰动
  - 解为(2, -1)

$$\begin{aligned}x_1 + 0.5x_2 &= 1.5 \\0.667x_1 + 0.334x_2 &= 1\end{aligned}$$

# 病态问题

- 输入数据的细微变化导致输出(解)的剧烈变化
- 将线性方程看成直线（超平面）
  - 当系统病态时，直线变为近似平行
  - 求解（即直线求交）变得困难、不精确



# 矩阵条件数

$$\kappa_2(A) = \frac{\max_{x \neq 0} \frac{\|Ax\|}{\|x\|}}{\min_{x \neq 0} \frac{\|Ax\|}{\|x\|}}$$

- 等于最大特征值和最小特征值之间比例
- 条件数大意味着基元之间有太多相关性


# 矩阵条件数

- 多项式插值问题是病态的
  - 对于等距分布的数据点 $x_i$ , 范德蒙矩阵的条件数随着数据点数 $n$ 呈指数级增长 (多项式的最高次数为 $n - 1$ )



# 为什么？


- 幂（单项式）函数基
  - 幂函数之间差别随着次数增加而减小
  - 不同幂函数之间唯一差别为增长速度( $x^i$ 比 $x^{i-1}$ 增长快)



幂(单项式) 函数


# 函数互相抵消

- 单项式：
  - 从左往右
  - 首先常函数1主宰
  - 接着 $x$ 增长最快
  - 接着 $x^2$ 增长最快
  - 接着 $x^3$ 增长最快
  - ...
- 趋势
  - 好的基函数一般需要系数交替
  - 互相抵消问题





# 解决方法

- 使用正交多项式基
- 如何获得?
  - Gram-Schmidt 正交化



# 多项式插值结果好吗？



振荡(龙格Runge)现象和对插值点数的高度敏感性  
观察 $n = 9$ (10个数据点)和 $n = 10$ (11个数据点)的差别

# 结论

- 多项式插值不稳定
    - 控制点的微小变化可导致完全不同的结果
  - 振荡(Runge)现象
    - 多项式随着插值点数(可以是细微)增加而摆动
- 需要更好的基函数来做插值
  - Bernstein基函数?
  - 分片多项式?

## 2. 多项式逼近


# 为什么逼近？

- 数据点含噪声、outliers等
- 更紧凑的表达
- 计算简单、更稳定

# 最小二乘逼近

- 逼近问题

- 给定一组线性无关的连续函数集合  $B = \{b_1, \dots, b_n\}$  和一组结点  $\{(x_1, y_1), \dots, (x_m, y_m)\}$ , 其中  $m > n$
- 在  $B$  张成空间中哪个函数  $f \in \text{span}(B)$  对结点逼近最好?
- 示例: 给定一组点, 找到最佳逼近的线性函数
- 怎么定义“最佳逼近”?




# 最佳逼近的定义

- 最小二乘逼近

$$\operatorname{argmin}_{f \in \operatorname{span}(B)} \sum_{j=1}^m (f(x_j) - y_j)^2$$

$$\begin{aligned}\sum_{j=1}^m (f(x_j) - y_j)^2 &= \sum_{j=1}^m \left( \sum_{i=1}^n \lambda_i b_i(x_j) - y_j \right)^2 \\ &= (M\lambda - y)^T (M\lambda - y) \\ &= \lambda^T M^T M \lambda - y^T M \lambda - \lambda^T M^T y + y^T y \\ &= \lambda^T M^T M \lambda - 2y^T M \lambda + y^T y\end{aligned}$$



$$M = \begin{pmatrix} b_1(x_1) & \dots & b_n(x_1) \\ \vdots & \ddots & \vdots \\ b_1(x_m) & \dots & b_n(x_m) \end{pmatrix}$$

# 求解

- 关于 $\lambda$ 的二次多项式

$$\lambda^T M^T M \lambda - 2y^T M \lambda + y^T y$$

- 法方程

- 最小解满足

$$M^T M \lambda = M^T y$$

- 提示

- 最小化二次目标函数  $x^T A x + b^T x + c$
  - 充分必要条件:  $2Ax = -b$

### 3. 函数空间及基函数







# 为什么用多项式？

- 易于计算，表现良好，光滑， ...
- 稠密性与完备性：表达能力足够！
  - 魏尔斯特拉斯Weierstrass定理：令 $f$ 为闭区间 $[a, b]$ 上任意连续函数，则对任意给定 $\varepsilon$ ，存在 $n$ 和多项式 $P_n$ 使得
$$|f(x) - P_n(x)| < \varepsilon, \forall x \in [a, b]$$
  - Weierstrass只证明了存在性，未给出多项式

# 用Bernstein多项式做逼近

- 伯恩斯坦Bernstein给出了构造性证明（强大！）
  - 对[0, 1]区间上任意连续函数 $f(x)$ 和任意正整数 $n$ , 以下不等式对所有 $x \in [0,1]$ 成立
$$|f(x) - B_n(f, x)| < \frac{9}{4} m_{f,n}$$
  - $m_{f,n}$  = lower upper bound  $|f(y_1) - f(y_2)|$   
 $y_1, y_2 \in [0,1] \text{ 且 } |y_1 - y_2| < \frac{1}{\sqrt{n}}$
  - $B_n(f, x) = \sum_{j=0}^n f(x_j) b_{n,j}(x)$ , 其中 $x_j$ 为[0,1]上等距采样点
  - $b_{n,j} = \binom{n}{j} x^j (1-x)^{n-j}$ 为Bernstein多项式


# Bernstein多项式



- $b_{0,0}(x) = 1$
- $b_{0,1}(x) = 1 - x, \quad b_{1,1} = x$
- $b_{0,2}(x) = (1 - x)^2, \quad b_{1,2} = 2x(1 - x), \quad b_{2,2} = x^2$
- $b_{0,3}(x) = (1 - x)^3, \quad b_{1,3} = 3x(1 - x)^2, \quad b_{2,3} = 3x^2(1 - x), \quad b_{3,3} = x^3$
- $b_{0,4}(x) = (1 - x)^4, \quad b_{1,4} = 4x(1 - x)^3, \quad b_{2,4} = 6x^2(1 - x)^2, \quad b_{3,4} = 4x^3(1 - x), \quad b_{4,4} = x^4$

# 用Bernstein多项式做逼近



- Bernstein基函数的良好性质：非常好的几何意义！
  - 正性、权性（和为1）→凸包性
  - 变差缩减性
  - 递归线性求解方法
  - 细分性
  - ...
- Bernstein多项式逼近示例
  - 逼近结果优秀
  - 需要高阶



丰富的理论：CAGD课程

# 关于Bernstein函数...

- $B_n(f, x) = \sum_{j=0}^n f\left(\frac{j}{n}\right) b_{n,j}(x)$
- 两种观点：
  - 几何观点、代数观点



丰富的理论：CAGD课程


## 4. RBF函数插值/逼近

# Gauss函数

- 两个参数：均值 $\mu$ , 方差 $\sigma^2$

$$g_{\mu,\sigma}(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- 几何意义：
  - 均值 $\mu$ : 位置
  - 方差 $\sigma^2$ : 支集宽度



- 不同均值和方差的Gauss函数都线性无关
  - 有什么启发？

# RBF函数拟合


- RBF函数

$$f(x) = b_0 + \sum_{i=1}^n b_i g_i(x)$$


- 方法

- 原因


# 讨论：现象




$$\sigma = 0.1$$



$$\sigma = 1$$





$$\sigma = 5$$



$$\sigma = 10$$

# 讨论：现象




# 思考：

- 均值 $\mu$ 和方差 $\sigma^2$ 是否可以一起来优化？

$$g_{\mu,\sigma}(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$f(x) = b_0 + \sum_{i=1}^n b_i g_i(x)$$

- 问题？



# 多元函数


# 多元函数（多变量）

- 多个变量的函数

$$f: R^n \rightarrow R^1 \quad \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \rightarrow y$$

$$y = f(x_1, x_2, \dots, x_n)$$

- 例子：二元函数  $z = f(x, y)$ ,  $(x, y) \in [0,1] \times [0,1]$



# 二元函数的基函数构造


- 方法：**张量积**形式，即用两个一元函数的基函数的相互乘积来定义
- 比如：二次二元多项式函数  $z = f(x, y)$  的基函数  $\{1, x, y, x^2, xy, y^2\}$

	1	$x$	$x^2$
1	1	$x$	$x^2$
$y$	$y$	$xy$	$x^2y$
$y^2$	$y^2$	$xy^2$	$x^2y^2$

# 三次张量积多项式

	1	$u$	$u^2$	$u^3$
1	1	$u$	$u^2$	$u^3$
$v$	$v$	$vu$	$vu^2$	$vu^3$
$v^2$	$v^2$	$v^2u$	$v^2u^2$	$v^2u^3$
$v^3$	$v^3$	$v^3u$	$v^3u^2$	$v^3u^3$

# 三次张量积函数



# 张量积基函数

	$b_1(u)$	$b_2(u)$	$b_3(u)$	$b_4(u)$
$b_1(v)$	$b_1(v)b_1(u)$	$b_1(v)b_2(u)$	$b_1(v)b_3(u)$	$b_1(v)b_4(u)$
$b_2(v)$	$b_2(v)b_1(u)$	$b_2(v)b_2(u)$	$b_2(v)b_3(u)$	$b_2(v)b_4(u)$
$b_3(v)$	$b_3(v)b_1(u)$	$b_3(v)b_2(u)$	$b_3(v)b_3(u)$	$b_3(v)b_4(u)$
$b_4(v)$	$b_4(v)b_1(u)$	$b_4(v)b_2(u)$	$b_4(v)b_3(u)$	$b_4(v)b_4(u)$

# 多元函数的张量积定义


- 优点：定义简单，多个一元基函数的乘积形式
- 不足：
  - 随着维数增加，基函数个数急剧增加，导致变量急剧增加（求解系统规模急剧增加，求解代价大）

	1	$x$	$x^2$
1	1	$x$	$x^2$
$y$	$y$	$xy$	$x^2y$
$y^2$	$y^2$	$xy^2$	$x^2y^2$

# 多元函数的神经网络表达

$$f: \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \rightarrow y$$

- 用一个单变量函数  $\sigma(x)$  (称为激活函数) 的不同仿射变换来构造“基函数”：基函数数目可



# 向量值函数

# 向量值函数（多个应变量）


- 先看单变量的:  $f: R^1 \rightarrow R^m$        $x \rightarrow \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$
- 看成多个单变量函数，各个函数独立无关
  - 一般会用同样的基函数（共享基函数）

$$\begin{cases} y_1 = f_1(x) \\ \vdots \\ y_m = f_m(x) \end{cases}$$

# 向量值函数（多个应变量）

$$f: R^1 \rightarrow R^m \quad \begin{cases} y_1 = f_1(x) \\ \vdots \\ y_m = f_m(x) \end{cases}$$


- 几何解释：
  - 一个实数  $x \in R^1$  映射到  $m$  维空间  $R^m$  的一个点，轨迹构成  $R^m$  的一条“曲线”
  - 本质维度为 1



# 特例：平面参数曲线

$$f: R^1 \rightarrow R^2 \quad \begin{cases} x = x(t) \\ y = y(t) \end{cases} \quad t \in [0,1]$$



- 几何解释：
  - 一条曲线由一个变量参数 $t$ 决定，也称为单参数曲线
  - 参数 $t$ 可看成该曲线的“时间”变量
  - 可灵活表达非函数型的曲线（任意曲线）



# 特例：空间参数曲线

$$f: R^1 \rightarrow R^3 \quad \begin{cases} x = x(t) \\ y = y(t) \\ z = z(t) \end{cases} \quad t \in [0,1]$$


- 几何解释：
  - 一条曲线由一个变量参数  $t$  决定，也称为单参数曲线
  - 参数  $t$  可看成该曲线的“时间”变量
  - 可灵活表达非函数型的



# 特例：参数曲面

$$f: \mathbb{R}^2 \rightarrow \mathbb{R}^3 \quad \begin{cases} x = x(u, v) \\ y = y(u, v) \\ z = z(u, v) \end{cases} \quad (u, v) \in [0,1] \times [0,1]$$


- 几何解释：
  - 一张曲面由两个参数 $(u, v)$ 决定，也称为双参数曲面
  - 可灵活表达非函数型



# 特例：二维映射

$$f: R^2 \rightarrow R^2 \quad \begin{cases} x = x(u, v) \\ y = y(u, v) \end{cases} \quad (u, v) \in [0,1] \times [0,1]$$


- 几何解释：
  - 二维区域之间的映射
  - 可看成特殊的曲面（第三个维度始终为0）
  - 应用：图像




# 特例：二维映射

$$f: R^3 \rightarrow R^3 \quad \begin{cases} x = x(u, v, w) \\ y = y(u, v, w) \\ z = z(u, v, w) \end{cases} \quad (u, v, w) \in [0,1]^3$$

- 几何解释：
  - 三维体区域之间的映射
  - 应用：体形变、体参数化



# 特例：降维映射（低维投影）









- 降维映射一般有信息丢失
  - 丢失的信息大部分情况下不可逆，即无法恢复

# 一般映射

$$f: R^n \rightarrow R^m$$

- 如果  $n < m$ , 为低维到高维的映射 (高维的超曲面,  $n$  维流形曲面), 本征维度为  $n$
- 如果  $n > m$ , 为降维映射
  - 一般信息有损失
  - 如果  $R^n$  中的点集刚好位于一个  $m$  维 (或小于  $m$ ) 的流形上, 则映射可能是无损的, 即可以被恢复的


# 低维空间之间的函数

	Output: 1D	Output: 2D	Output: 3D
Input: 1D	 Function graph	 Plane curve	 Space curve
Input: 2D		 Plane warp	 Surface
Input: 3D			 Space warp


# 曲线拟合

# 曲线拟合问题

- 输入：给定平面上系列点 $(x_i, y_i), i = 1, 2, \dots, n$
- 输出：一条参数曲线， $\begin{cases} x = x(t) \\ y = y(t) \end{cases}$  拟合这些点  $t \in [0, 1]$



# 曲线拟合问题



$$\begin{cases} x = x(t) \\ y = y(t) \end{cases} \quad t \in [0,1]$$

- 问题: 对数据点 $(x_i, y_i)$ , 对应哪个参数 $t_i$ ?


矢量符号化表达:

$$\mathbf{p} = \mathbf{p}(t) = \begin{pmatrix} x(t) \\ y(t) \end{pmatrix}$$

- 误差度量:  $E = \sum_{i=1}^n \left\| \begin{pmatrix} x(t_i) \\ y(t_i) \end{pmatrix} - \begin{pmatrix} x_i \\ y_i \end{pmatrix} \right\|^2 = \sum_{i=1}^n \|\mathbf{p}(t_i) - \mathbf{p}_i\|^2$

# 参数化问题

- 求数据点所对应的参数：一个降维的问题！



- 然后极小化误差度量： $E = \sum_{i=1}^n \|p(t_i) - p_i\|^2$

# 点列的参数化


- Equidistant (uniform) parameterization
  - $t_{i+1} - t_i = \text{const}$
  - e.g.  $t_i = i$
  - Geometry of the data points is not considered
- Chordal parameterization
  - $t_{i+1} - t_i = \|\mathbf{k}_{i+1} - \mathbf{k}_i\|$
  - Parameter intervals proportional to the distances of neighbored control points

# 点列的参数化


- Centripetal parameterization
  - $t_{i+1} - t_i = \sqrt{\|\mathbf{k}_{i+1} - \mathbf{k}_i\|}$
- Foley parameterization
  - Involvement of angles in the control polygon
  - $t_{i+1} - t_i = \|\mathbf{k}_{i+1} - \mathbf{k}_i\| \cdot \left( 1 + \frac{3}{2} \frac{\hat{\alpha}_i \|\mathbf{k}_i - \mathbf{k}_{i-1}\|}{\|\mathbf{k}_i - \mathbf{k}_{i-1}\| + \|\mathbf{k}_{i+1} - \mathbf{k}_i\|} + \frac{3}{2} \frac{\hat{\alpha}_{i+1} \|\mathbf{k}_{i+1} - \mathbf{k}_i\|}{\|\mathbf{k}_{i+1} - \mathbf{k}_i\| + \|\mathbf{k}_{i+2} - \mathbf{k}_{i+1}\|} \right)$
  - with  $\hat{\alpha}_i = \min\left(\pi - \alpha_i, \frac{\pi}{2}\right)$
  - and  $\alpha_i = \text{angle}(\mathbf{k}_{i-1}, \mathbf{k}_i, \mathbf{k}_{i+1})$

# 一个例子

- Examples: Uniform parameterization



Curve




Curvature plot

# 一个例子

- Examples: Chordal parameterization




Curve



Curvature plot



# 一个例子

- Examples: Centripetal parameterization




# 一个例子

- Examples: Foley parameterization




# 另一个例子



点的参数化对曲线拟合的影响很大，需要**好的参数化**！


# 曲面参数化

- 三维的点找二维的参数：一个降维的问题！






# 曲面参数化的应用

- 地图绘制（地理学）



# 曲面参数化的应用

- 纹理映射



# Recap: Interpolation

- Nearest neighborhood
- Bicubic
- Spline
- Thin plate spline
- ...

# Image Warping

# 图像变形

- 特定效果的变形



# 图像变形

- 特定效果的变形





# 用户交互




[Demo](#)

# 如何做到的？



# 数学原理

- 散乱点插值



**Thanks!**